

VILNIAUS UNIVERSITETAS
INFORMATIKOS INSTITUTAS
PROGRAMŲ SISTEMOS

Sustiprinto mokymosi taikymas žaidimo agento valdymo programos kūrimui

Application of reinforcement learning to the software development for game agent management

Bakalauro baigiamojo darbo planas

Atliko: Jokūbas Rusakevičius (parašas)

Darbo vadovas: <reikia parašyti pareigas> Virginijus Marcinkevičius (parašas)

Darbo recenzentas: (parašas)

Vilnius – 2020

Tyrimo objektas ir aktualumas

Darbo Tikslas, keliami uždaviniai ir laukiami rezultatai

Šio darbo **tikslas** – išanalizavus populiariausius sustiprinto mokymosi algoritmus, pritaikyti labiausiai tinkamą algoritmą parinktai eksperimentiniai aplinkai bei pagerinti gaunamus rezultatus pritaikius agento mokymosi gerinimo principus.

Darbui iškelti **uždaviniai**:

1. Paruošti eksperimentinę aplinką ir agentą.
2. Apmokyti agentą.
3. Palyginti gaunamą agento efektyvumą atliekant aplinkoje realizuotą užduotį, keičiant aplinkos bei agento mokymosi kriterijus.
4. Pateikti rekomendacijas agento apmokymui parinktoje aplinkoje.

Darbo metu laukiami **rezultatai**:

1. Paruošta eksperimentinė aplinka ir agentas.
2. Apmokytas agentas.
3. Pakeisti aplinkos ir agento mokymosi kriterijai, palyginti gaunami rezultatai ir taip pasiektas geriausias užduoties atlikimas.
4. Pateiktos rekomendacijos agento apmokymui parinktoje aplinkoje.

Tyrimo metodas

Darbui atlikti bus naudojami šie tyrimo metodai:

1. **Mokslinės literatūros analizė.**
2. **Eksperimentas.**

Kiekybinis metodas – apmokyti pirminius agentus, stebėti jų elgseną. Atliekamas, su keliais skirtingais kriterijais ir ieškoma tinkamiausio bei daugiausiai žadančio pradinio rezultato eksperimentui.

Kokybinis metodas – su gautais pradiniais agentais bei jų mokymosi kriterijais atliekamos gilesnės kriterijų bei agento mokymosi parametrų manipuliacijos bei stebimi gaunamų rezultatų pakitimai.

3. **Gautų duomenų ir rezultatų analizė.**

Numatomas darbo atlikimo procesas

Darbas procesas susidės iš kelių skirtingų dalių:

1. Visų pirma, eksperimentui atlikti bus paruošta eksperimentinė aplinka.
2. Agento paruošimas bus atliekamas pasirenkant pradinius, neutralius mokymosi kriterijus.
3. Atliekamas pirminis agento apmokymas, skirtas eksperimento bazei gauti bei įsitikinti aplinkos ir agento tarpusavio veikla.
4. Pradėjus pagrindinę eksperimento dalį bus ieškoma ir eksperimentuojama su metodais, kurie pagerintų aukščiau gauti rezultatus.

5. Galutinė analizė visų atliktų tyrimų ir gautų rezultatų.
6. Pateikiama rekomendacija, kaip pagerinti agento apmokymą parinktai aplinkai ir jos keliamoms problemoms bei uždaviniams.

Darbai aktualūs literatūros šaltiniai

1. **[BGM⁺17]** – Standfordo Universiteto išleistas straipsnis apie jų vystomą „MacroBase“ analitinį įrankį bei jo apžvalga. Šiame leidinyje yra pristatomas pats įrankis, paaiškinamas kiekvienas iš jo naudojamų darbo proceso aspektų bei principų. Tai svarbus šaltinis naudojantis „MacroBase“.
2. **[BGR⁺17]** – Standfordo Universiteto išleistas straipsnis. Šiame leidinyje yra rašoma daugiau apie pačius principus ir teoriją, o ne apie „MacroBase“ analitinį įrankį.
3. **[RB17]** – Standfordo Universiteto straipsnis apie laiko intervalu fiksuojamus duomenis bei jų išlyginimą, padaryma lengviau skaitomais. Straipsnyje tai vadinama ASAP, analitiniu operatoriumi, kuris automatiškai išlygina įrašų rinkinį, taip padidinant analizuojamų duomenų gautų rezultatų tikslumą, bei sumažinant skaičiavimams reikalingą greitį.

Literatūra

- [Ast16] Anthony Asta. Observability at twitter: technical overview, part i. 2016. URL: https://blog.twitter.com/engineering/en_us/a/2016/observability-at-twitter-technical-overview-part-i.html (tikrinta 2019-03-10).
- [BGM⁺17] Peter Bailis, Edward Gan, Samuel Madden, Deepak Narayanan, Kexin Rong ir Sahaana Suri. Macrobases: prioritizing attention in fast data. *SIGMOD'17- Proceedings of the 2017 ACM International Conference on Management of Data*, p. 541–556, Chicago, Illinois, USA. Stanford Infolab ir Massachusetts Institute of Technology, ACM New York, 2017. ISBN: 978-1-4503-4197-4.
- [BGR⁺17] Peter Bailis, Edward Gan, Kexin Rong ir Sahaana Suri. Prioritizing attention in fast data: principles and promise. *CIDR 2017, 8th Biennial Conference on Innovative Data Systems Research*. Stanford Infolab, 2017.
- [HA17] Makrufa Sh. Hajirahimova ir Aybeniz S. Aliyeva. About big data measurement methodologies and indicators. *International Journal of Modern Education and Computer Science*, 9:1–9, 2017.
- [PFT⁺15] Tuomas Pelkonen, Scott Franklin, Justin Teller, Paul Cavallaro, Qi Huang, Justin Meza ir Kaushik Veeraraghavan. Gorilla: a fast, scalable, in-memory time series database. *VLDB Endowment - Proceedings of the 41st International Conference on Very Large Data Bases*, p. 1816–1827, Kohala Coast, Hawaii. Facebook Inc., 2015. (Tikrinta 2019-03-10).
- [RB17] Kexin Rong ir Peter Bailis. Asap: prioritizing attention via time series smoothing. *Proc. VLDB Endow.*, 10(11):1358–1369, 2017-08. ISSN: 2150-8097. DOI: 10.14778/3137628.3137645. URL: <https://doi.org/10.14778/3137628.3137645>.
- [rrtar18] Lietuvos Respublikos ryšių reguliavimo tarnyba. Interneto prieigos stebėsenos sistema ipss. 2018. URL: <https://opendata.rrt.lt/ipss> (tikrinta 2019-03-08).
- [Rus18] Jokūbas Rusakevičius. *Didelių duomenų srautų analizė, anomalijų aptikimas*. Kursinis darbas, Vilniaus Universitetas, Matematikos ir Informatikos Fakultetas, Vilnius, 2018.
- [Tec18] Techopedia. Anomaly detection. 2018. URL: <https://www.techopedia.com/definition/30297/anomaly-detection> (tikrinta 2019-03-07).
- [Woo15] Alex Woodie. Kafka tops 1 trillion messages per day at linkedin. 2015. URL: <https://www.datanami.com/2015/09/02/kafka-tops-1-trillion-messages-per-day-at-linkedin/> (tikrinta 2019-03-10).